

张光义

✉ zhangguangyi@zju.edu.cn · ☎ (+86) 158-5642-5942 · 🌐 Homepage · G
Google Scholar (Cited 1100)



🎓 教育经历

- 浙江大学 (Zhejiang University, ZJU) 2022.09 – Present
- 学位信息：信息与工程学院 · 信息与通信工程 · 工学博士
 - 研究方向：无线通信、图像压缩、联合信源信道编码等
 - 研究成果：第一作者发表 CCF-A 类论文 2 篇，SCI 期刊论文 8 篇，Google Scholar 被引 1100 余次
- 伦敦国王学院 (King's College London, KCL, 联培) 2024.12 – 2025.11
- 联培单位：工程学院 · 信号处理实验室
 - 研究方向：大语言模型投机解码、风险监控等
- 浙江大学 (Zhejiang University, ZJU) 2018.09 – 2022.06
- 学位信息：信息与工程学院 · 信息工程 · 工学学士
 - 学业成绩：GPA 4.41/5.00, Top 10%

🏆 荣誉奖励

- IEEE TCOM 2026 年最佳论文奖 (Top 0.1%) 2026.07
- 博士生国家奖学金 (Top 2%) 2025.10
- 中国科协青年人才托举计划博士生专项 (Top 1%) 2025.02
- 华为菁英杯算法大赛华东赛区三等奖 2024.09
- 浙江大学五好研究生 2023.10 & 2024.10
- 浙江大学优秀毕业生 2022.06

💼 实习经历

- 蚂蚁金服 2025.12 – 2026.04
- 技术：VLM、Agent、空间推理
 - 工作一：混合线性注意力视觉语言模型推理加速
基于 Lightning Attention 与混合线性注意力机制，完成 VLM/LLM 长上下文推理优化及 vLLM 后端适配开发；解决 CUDA Graph 与 Attention Metadata 不适配问题；解析 vLLM 多模态推理时间构成，通过预裁剪和引入多模态 Hash 字段降低预处理时延；在 A100 上完成 48k 上下文单请求测试，推理吞吐提升约 20%，并进一步适配 Jetson Orin 边缘平台获得约 30% 加速；为后续团队多模态基座模型 Ling 训练提供效率参考
 - 工作二：视觉语言空间推理 Agent 研究
基于 ReAct 机制完成面向视觉语言模型的空间智能推理任务，完成 VGGT、Grounding DINO、Depth Anything 等核心视觉基础模型的 Toolkit 化开发与集成；通过流程和 Prompt 工程优化，在 VSI-Bench 上实现约 10% 增益；采用大模型生成推理思维链构建 SFT 数据集，用于增强小模型的指令遵循能力和空间推理工具调用能力

⚙️ 主要科研经历

- 基于多任务 Transformer 的多模态语义通信 TCOM | 🌐
- 设计多任务 Transformer 编解码框架，实现文本、图像、语音的统一语义表示与任务共享
 - 融合 BERT/ViT、跨模态注意力和张量量化，支持多任务并行传输并降低语义特征开销
- 可学习式无线图像传输系统 AAAI、TCCN、TCOM | 🌐
- 构建层次 VAE 驱动的无线图像传输系统，实现多尺度语义特征的压缩、调制与重建
 - 结合可学习量化和反馈式概率采样，自适应调整传输符号，取得领域 SOTA 表现

- 将 Stable Diffusion 先验引入 JSCC 解码端，缓解超低带宽下的纹理缺失和语义幻觉
- 通过 LoRA 微调适配噪声信道，并利用熵模型进行速率分配，取得领域 SOTA 的生成式传输性能

量化-采样-验证式大语言模型边云推理加速

COMML, NeurIPS-Workshop | 

- 设计量化-采样-验证式投机解码框架，降低边云协同 LLM 推理的通信开销与验证延迟
- 结合概率量化、强化学习和流水线并行，动态调度草稿 token、量化精度和验证策略

基于预测驱动推断的大语言模型性能风险评估

ICML

- 构建预测驱动推断框架，将未标注样本纳入 LLM 在线性能监控和半监督风险估计
- 结合自适应依赖设计与自填补策略提升可靠性，在 LLM 辅助监控场景中提高检测效率

 主要科研成果

- [1] **G. Zhang**, Q. Hu, Z. Qin, Y. Cai, *et al.* “A Unified Multi-Task Semantic Communication System for Multimodal Data.” IEEE Transactions on Communications (TCOM), 2024. **(ESI Hot)**
- [2] **G. Zhang**, H. Li, Y. Cai, Q. Hu, *et al.* “Learned Image Transmission with Hierarchical Variational Autoencoder.” Annual AAAI Conference on Artificial Intelligence (AAAI), 2025. **(CCF-A)**
- [3] **G. Zhang**, Y. Cai, G. Yu, O. Simeone, *et al.* “Prediction-Powered Risk Monitoring: A Semi-Supervised Framework for Sequential Testing.” International Conference on Machine Learning (ICML) 2026. **(CCF-A)**
- [4] **G. Zhang**, H. Li, Y. Cai, Q. Hu, *et al.* “Progressive Learned Image Transmission for Semantic Communication Using Hierarchical VAE.” IEEE Transactions on Cognitive Communications and Networking (TCCN), 2025. **(TCCN Popular Documents-2025)**
- [5] **G. Zhang**, P. Yang, Y. Cai, Q. Hu *et al.* “From Analog to Digital: Multi-Order Digital Joint Coding-Modulation for Semantic Communication.” IEEE Transactions on Communications (TCOM), 2024. **(TCOM Popular Documents-2024)**
- [6] **G. Zhang**, K. Kang, Y. Cai, Q. Hu *et al.* “O2SC: Realizing Channel-Adaptive Semantic Communication With One-Shot Online-Learning.” IEEE Transactions on Communications (TCOM), 2024.
- [7] **G. Zhang**, Q. Hu, Y. Cai, G. Yu. “SCAN: Semantic Communication with Adaptive Channel Feedback.” IEEE Transactions on Cognitive Communications and Networking (TCCN), 2024.
- [8] **G. Zhang**, K. Zhou, Y. Cai, Q. Hu *et al.* “Toward Compatible Semantic Communication: A Perspective on Digital Coding and Modulation,” IEEE Communications Magazine (COMMAG), 2025.
- [9] **G. Zhang**, Y. Cai, G. Yu, P. Popovski, *et al.* “Quantize-Sample-and-Verify: LLM Acceleration via Adaptive Edge-Cloud Speculative Decoding.” IEEE Communications Letters (COMML), 2025.
- [10] **G. Zhang**, Q. Hu, Y. Cai, G. Yu. “Alleviating Distortion Accumulation in Multi-Hop Semantic Communication.” IEEE Communications Letters (COMML), 2024.
- [11] H. Li, **G. Zhang**, K. Zhou, Y. Cai, *et al.* “Coarse-to-Fine: A Dual-Phase Channel-Adaptive Method for Wireless Image Transmission.” IEEE Transactions on Wireless Communications (TWC), 2025.
- [12] Q. Hu, **G. Zhang**, Z. Qin, Y. Cai, *et al.* “Robust Semantic Communications With Masked VQ-VAE Enabled Codebook.” IEEE Transactions on Wireless Communications (TWC), 2023. **(ESI Highly Cited)**
- [13] K. Zhou, **G. Zhang**, Y. Cai, Q. Hu, *et al.* “ROME: Robust Model Ensembling for Semantic Communication Against Semantic Jamming Attacks,” IEEE Transactions on Wireless Communications (TWC), 2023.
- [14] K. Zhou, **G. Zhang**, Y. Cai, Q. Hu, *et al.* “Feature Allocation for Semantic Communication With Space-Time Importance Awareness,” IEEE Transactions on Wireless Communications (TWC), 2023.
- [15] P. Bhattacharjee, F. Tian, M. Zhong, **G. Zhang**, *et al.* “Conformal Sparsification for Bandwidth-Efficient Edge-Cloud Speculative Decoding.” Advances in Neural Information Processing Systems Workshop (NeurIPS WS), 2025.

 专业技能

编程/框架：Python, PyTorch, vLLM, C, MATLAB

模型方向：LLM, VLM, Transformer, Diffusion, VAE, GAN, Agent

语言能力：CET-6, IELTS (6.5)